

Perbandingan K-Means dan DBSCAN (Euclidean, Manhattan, Cosine) pada Dataset Diabetes Health Indicators (BRFSS 2015)

1. K-Means (Euclidean, Manhattan, Cosine)

a. Parameter:


| Parameter    | Nilai          | Parameter         | Nilai     |
|--------------|----------------|-------------------|-----------|
| Data         | 208.858 × 20   | k                 | 4 (Elbow) |
| Scaling      | StandardScaler | Inisialisasi      | K-Means++ |
| Max iterasi  | 300            | Toleransi         | 0,0001    |
| Random state | 42             | Sampel Silhouette | 10.000    |

Formatted: Centered

Pembaruan centroid: Euclidean memakai rata-rata (mean), Manhattan memakai median, Cosine memakai rata-rata yang dinormalisasi ke panjang 1 (data Cosine juga dinormalisasi L2).

b. Tabel Komparasi dan Visualisasi Kluster

| TABEL KOMPARASI K-MEANS: EUCLIDEAN vs MANHATTAN vs COSINE (k = 4) |                 |                      |                          |                             |                        |            |                     |                     |                     |                          |
|-------------------------------------------------------------------|-----------------|----------------------|--------------------------|-----------------------------|------------------------|------------|---------------------|---------------------|---------------------|--------------------------|
|                                                                   | Distance Metric | Silhouette Score (↑) | Davies-Bouldin Index (↓) | Calinski-Harabasz Index (↑) | Execution Time (s) (↓) | Iterations | Objective Value (↓) | ARI vs Diabetes (↑) | NMI vs Diabetes (↑) | Ukuran Kluster (min-max) |
| 0                                                                 | Euclidean       | 0.0811               | 2.6378                   | 17124.85                    | 6.269                  | 43         | 3352501.30          | 0.0631              | 0.0589              | 11.827 – 87.571          |
| 1                                                                 | Manhattan       | 0.1299               | 2.9811                   | 12961.67                    | 0.929                  | 4          | 21663057.87         | 0.0692              | 0.0486              | 12.000 – 98.975          |
| 2                                                                 | Cosine          | 0.1642               | 2.8177                   | 15784.16                    | 2.339                  | 21         | 73183.98            | 0.0197              | 0.0368              | 34.836 – 64.236          |



c. Analisis

| Metrik    | Kelebihan                                                                                                                                                          | Kekurangan                                                                                       |
|-----------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| Euclidean | Davies–Bouldin (2,638), Calinski–Harabasz (17.125), dan NMI (0,059) terbaik. Rata-rata peringkat terbaik (1,83). Risiko terpisah paling tajam: 4,86% sampai 34,38% | Paling lambat (6,27 detik, 43 iterasi). Ukuran kluster paling timpang (11.827 sampai 87.571)     |
| Manhattan | Tercepat (0,93 detik, 4 iterasi). ARI tertinggi (0,069)                                                                                                            | Davies–Bouldin (2,981) dan Calinski–Harabasz (12.962) terburuk. Satu kluster menampung ±47% data |
| Cosine    | Silhouette tertinggi (0,164). Ukuran kluster paling seimbang                                                                                                       | NMI (0,037) dan ARI (0,020) terendah. Rentang risiko paling sempit: 7,72% sampai 32,53%          |

d. Kesimpulan

Euclidean paling cocok di antara ketiganya, karena paling konsisten pada kualitas kluster dan paling baik memisahkan kelompok berisiko tinggi. Kluster berisiko tertingginya (34,38% diabetes) berisi responden dengan kesehatan umum buruk, kesulitan berjalan, dan riwayat stroke.

## 2. DBSCAN (Euclidean, Manhattan, Cosine)


### a. Parameter

- Preprocessing: StandardScaler, lalu sampling acak 10.000 data (random\_state=42) agar DBSCAN brute-force tetap cepat.
- MinPts = 40 ( $2 \times$  jumlah fitur), sama untuk semua metrik.
- Penentuan eps: dari grafik k-distance ( $k = 40$ ), dicoba pada persentil 50, 60, 70, 80, 90, dan 95 untuk tiap metrik.
- Kriteria kandidat terbaik: minimal 2 kluster berukuran  $\geq 1\%$  data, noise  $\leq 30\%$ , lalu dipilih yang Silhouette (euclidean)-nya tertinggi. Silhouette dihitung dengan metrik euclidean untuk ketiganya supaya perbandingannya adil.

### b. Hasil Konfigurasi

|           | eps    | MinPts | Kluster | Kluster<br>>=1% | Noise<br>(n) | Noise<br>(%) | Kluster<br>terbesar<br>(%) | Waktu<br>(s) | Silhouette<br>(metrik<br>sendiri) | Silhouette<br>(euclidean) | DBI      | CHI        | persentil |
|-----------|--------|--------|---------|-----------------|--------------|--------------|----------------------------|--------------|-----------------------------------|---------------------------|----------|------------|-----------|
| Metrik    |        |        |         |                 |              |              |                            |              |                                   |                           |          |            |           |
| euclidean | 4.4344 | 40     | 3       | 3               | 308          | 3.08         | 89.97                      | 2.17         | 0.227392                          | 0.227392                  | 1.565536 | 507.822424 | 90        |
| manhattan | 4.9644 | 40     | 2       | 2               | 2779         | 27.79        | 70.50                      | 2.24         | 0.215542                          | 0.267991                  | 1.194762 | 339.055912 | 50        |
| cosine    | 0.2658 | 40     | 3       | 3               | 604          | 6.04         | 79.87                      | 2.09         | 0.091977                          | 0.159632                  | 2.136715 | 582.533548 | 60        |

euclidean | eps 4.4344 | kluster 3 | noise 308  
manhattan | eps 4.9644 | kluster 2 | noise 2779  
cosine | eps 0.2658 | kluster 3 | noise 604



### c. Analisis

- Manhattan unggul di Silhouette dan DBI, tetapi hasilnya kurang bisa dipercaya. Hampir 28% data dibuang sebagai noise dan hanya terbentuk 2 kluster. Nilai evaluasinya hanya dihitung pada data non-noise, jadi skor yang tinggi sebagian berasal dari banyaknya data sulit yang dikeluarkan. Pada eps yang lebih besar, Manhattan langsung menyatu menjadi 1 kluster.
- Cosine punya CHI tertinggi dan distribusi kluster paling merata, tetapi Silhouette terendah dan DBI terburuk, artinya kluster saling tumpang tindih. Hal ini wajar karena cosine hanya melihat arah vektor, bukan besaran nilai. Padahal fitur seperti BMI, Age, dan GenHlth justru bermakna lewat besarnya.
- Euclidean paling seimbang: noise paling rendah (3,08%), 3 kluster terbentuk, dan data yang tercakup paling banyak. Kualitas klasternya juga cukup baik (Silhouette 0,227, DBI 1,566).

### d. Kesimpulan

DBSCAN dengan metrik Euclidean (eps = 4,4344. MinPts = 40) dipilih sebagai yang paling cocok untuk data kesehatan BRFSS yang sudah distandarisasi, karena menjaga keseimbangan antara kualitas kluster dan cakupan data (noise hanya 3,08%). Metrik ini juga cocok dengan data numerik terstandarisasi yang besaran nilainya bermakna.