

Perbandingan K-Means dan DBSCAN (Euclidean, Manhattan, Cosine) pada Dataset Diabetes Health Indicators (BRFSS 2015)

1. K-Means (Euclidean, Manhattan, Cosine)

a. Parameter:

Parameter	Nilai	Parameter	Nilai
Data	208.858 × 20	k	4 (Elbow)
Scaling	StandardScaler	Inisialisasi	K-Means++
Max iterasi	300	Toleransi	0,0001
Random state	42	Sampel Silhouette	10.000


Pembaruan centroid: Euclidean memakai rata-rata (mean), Manhattan memakai median, Cosine memakai rata-rata yang dinormalisasi ke panjang 1 (data Cosine juga dinormalisasi L2).

b. Tabel Komparasi dan Visualisasi Kluster

TABEL KOMPARASI K-MEANS: EUCLIDEAN vs MANHATTAN vs COSINE (k = 4)

	Distance Metric	Silhouette Score (↑)	Davies-Bouldin Index (↓)	Calinski-Harabasz Index (↑)	Execution Time (s) (↓)	Iterations	Objective Value (↓)	ARI vs Diabetes (↑)	NMI vs Diabetes (↑)	Ukuran Kluster (min-max)
0	Euclidean	0.0811	2.6378	17124.85	6.269	43	3352501.30	0.0631	0.0589	11,827 – 87,571
1	Manhattan	0.1299	2.9811	12961.67	0.929	4	21663057.87	0.0692	0.0486	12,000 – 98,975
2	Cosine	0.1642	2.8177	15784.16	2.339	21	73183.98	0.0197	0.0368	34,836 – 64,236

Pemetaan Kluster K-Means pada PCA 2D (k = 4)



c. Analisis

Metrik	Kelebihan	Kekurangan
Euclidean	Davies-Bouldin (2,638), Calinski-Harabasz (17.125), dan NMI (0,059) terbaik. Rata-rata peringkat terbaik (1,83). Risiko terpisah paling tajam: 4,86% sampai 34,38%	Paling lambat (6,27 detik, 43 iterasi). Ukuran kluster paling timpang (11.827 sampai 87.571)
Manhattan	Tercepat (0,93 detik, 4 iterasi). ARI tertinggi (0,069)	Davies-Bouldin (2,981) dan Calinski-Harabasz (12.962) terburuk. Satu kluster menampung ±47% data
Cosine	Silhouette tertinggi (0,164). Ukuran kluster paling seimbang	NMI (0,037) dan ARI (0,020) terendah. Rentang risiko paling sempit: 7,72% sampai 32,53%

d. Kesimpulan

Euclidean paling cocok di antara ketiganya, karena paling konsisten pada kualitas kluster dan paling baik memisahkan kelompok berisiko tinggi. Kluster berisiko tertingginya (34,38% diabetes) berisi responden dengan kesehatan umum buruk, kesulitan berjalan, dan riwayat stroke.

2. DBSCAN (Euclidean, Manhattan, Cosine)


a. Parameter

- Preprocessing: StandardScaler, lalu sampling acak 10.000 data (random_state=42) agar DBSCAN brute-force tetap cepat.
- MinPts = 40 ($2 \times$ jumlah fitur), sama untuk semua metrik.
- Penentuan eps: dari grafik k-distance ($k = 40$), dicoba pada persentil 50, 60, 70, 80, 90, dan 95 untuk tiap metrik.
- Kriteria kandidat terbaik: minimal 2 klaster berukuran $\geq 1\%$ data, noise $\leq 30\%$, lalu dipilih yang Silhouette (euclidean)-nya tertinggi. Silhouette dihitung dengan metrik euclidean untuk ketiganya supaya perbandingannya adil.

b. Hasil Konfigurasi

	eps	MinPts	Klaster	Klaster >=1%	Noise (n)	Noise (%)	Klaster terbesar (%)	Waktu (s)	Silhouette (metrik sendiri)	Silhouette (euclidean)	DBI	CHI	persentil
Metrik													
euclidean	4.4344	40	3	3	308	3.08	89.97	2.17	0.227392	0.227392	1.565536	507.822424	90
manhattan	4.9644	40	2	2	2779	27.79	70.50	2.24	0.215542	0.267991	1.194762	339.055912	50
cosine	0.2658	40	3	3	604	6.04	79.87	2.09	0.091977	0.159632	2.136715	582.533548	60

euclidean | eps 4.4344 | klaster 3 | noise 308
manhattan | eps 4.9644 | klaster 2 | noise 2779
cosine | eps 0.2658 | klaster 3 | noise 604



c. Analisis

- Manhattan unggul di Silhouette dan DBI, tetapi hasilnya kurang bisa dipercaya. Hampir 28% data dibuang sebagai noise dan hanya terbentuk 2 klaster. Nilai evaluasinya hanya dihitung pada data non-noise, jadi skor yang tinggi sebagian berasal dari banyaknya data sulit yang dikeluarkan. Pada eps yang lebih besar, Manhattan langsung menyatu menjadi 1 klaster.
- Cosine punya CHI tertinggi dan distribusi klaster paling merata, tetapi Silhouette terendah dan DBI terburuk, artinya klaster saling tumpang tindih. Hal ini wajar karena cosine hanya melihat arah vektor, bukan besaran nilai. Padahal fitur seperti BMI, Age, dan GenHlth justru bermakna lewat besarannya.
- Euclidean paling seimbang: noise paling rendah (3,08%), 3 klaster terbentuk, dan data yang tercakup paling banyak. Kualitas klasternya juga cukup baik (Silhouette 0,227, DBI 1,566).

d. Kesimpulan

DBSCAN dengan metrik Euclidean (eps = 4,4344. MinPts = 40) dipilih sebagai yang paling cocok untuk data kesehatan BRFSS yang sudah distandarisasi, karena menjaga keseimbangan antara kualitas klaster dan cakupan data (noise hanya 3,08%). Metrik ini juga cocok dengan data numerik terstandarisasi yang besaran nilainya bermakna.